

Δομή κώδικα

- Επεξεργασία Δεδομένων, ανάλυση δεδομένων και δημιουργία του νέου train_set (create_custom_train_set.ipynb)
- Εξαγωγή νέων δεδομένων και πιθανών στηλών για αφαίρεση κατά το model training (edited_train_set.csv, drop_cols.txt)
- Εκπαίδευση των μοντέλων ML και εφαρμογή στο test set του διαγωνισμού(algorithms.ipynb)
- Εξαγωγή νέων δεδομένων (predicted_household_consumption.csv,predicted_poverty_distribution.csv)

Final Project

```
|— DrivenData Folder
|— create_custom_train_set.ipynb
|— algorithms.ipynb
|— edited_train_set.csv
|— drop_cols.txt
|— predicted_household_consumption.csv
|— predicted_poverty_distribution.csv
```

Επεξεργασία Δεδομένων

Τα δεδομένα του household features ενώθηκαν με τις ετικέτες κατανάλωσης (cons_ppp17) μέσω των keys survey_id και hhid. Επαληθεύτηκε η απουσία διπλοεγγραφών και ελλειπουσών τιμών στη μεταβλητή-στόχο.

Αφαιρέθηκαν χαρακτηριστικά χωρίς διακύμανση, καθώς και αναγνωριστικά πεδία (survey_id, hhid) που δεν συνεισφέρουν στην πρόβλεψη. Επιπλέον, αφαιρέθηκε η μεταβλητή φύλου για αποφυγή εισαγωγής μεροληψίας.

Οι κατηγορικές μεταβλητές με δύο μοναδικές τιμές μετατράπηκαν σε δυαδική αριθμητική μορφή (0/1), ενώ για μεταβλητές με περισσότερες κατηγορίες εφαρμόστηκε one-hot encoding.

Δημιουργήθηκαν σύνθετα χαρακτηριστικά μέσω σύνοψης ομάδων μεταβλητών, όπως συνολική κατανάλωση τροφίμων, αριθμός παιδιών και δείκτης απασχολούμενων ενηλίκων, μειώνοντας τη διασασιμότητα των δεδομένων.

Οι ελλείπουσες τιμές στις αριθμητικές μεταβλητές συμπληρώθηκαν με τη διάμεσο, ενώ στις κατηγορικές με την επικρατέστερη τιμή (mode).

Το τελικό σύνολο δεδομένων δεν περιέχει ελλείπουσες τιμές και αποτελείται αποκλειστικά από αριθμητικά χαρακτηριστικά.

Επίσης, κατά την προετοιμασία του test set εφαρμόστηκε επιπλέον imputation ώστε να αφαιρεθούν πλήρως τα missing values, καθώς το Gradient Boosting δεν υποστηρίζει NaN τιμές κατά την πρόβλεψη.

Επεξήγηση Αποτελεσμάτων

- *Περιορισμοί των μοντέλων*

Lasso Regression

Υποθέτουν γραμμική σχέση μεταξύ χαρακτηριστικών και στόχου, γεγονός που περιορίζει την ικανότητά τους να αποτυπώσουν τις πολύπλοκες μη γραμμικές αλληλεπιδράσεις των δεδομένων του dataset..

Support Vector Regression(SVR)

Αυξημένο υπολογιστικό κόστος και ευαισθησία στην επιλογή υπερ παραμέτρων (kernel, C, γ), ενώ η ερμηνευσιμότητά τους είναι περιορισμένη.

Gradient Boosting

Παρότι προσφέρουν υψηλή ακρίβεια, χρειάζεται πολύ καλό fine-tuning για αποφυγί overfitting των αποτελεσμάτων και έχουν μειωμένη διαφάνεια ως προς τη λήψη αποφάσεων.

Deep Learning - MLP

Απαιτούν επαρκή ποσότητα δεδομένων και προσεκτική ρύθμιση υπερ παραμέτρων, ενώ η διαδικασία εκπαίδευσης είναι πιο απαιτητική υπολογιστικά και τα αποτελέσματά τους δύσκολα ερμηνεύσιμα.

Γενικά, όλα τα μοντέλα επηρεάζονται από την ποιότητα των δεδομένων, πιθανές μεροληψίες στις έρευνες και την υπόθεση ότι τα χαρακτηριστικά του training set είναι αντιπροσωπευτικά των δεδομένων δοκιμής. Επίσης όλα απαιτούν κατάλληλο χειρισμό των NaN τιμών, το οποίο σε ένα test set παρεμβαίνει στην αξιοπιστία των prediction.

Στις δοκιμές για το test csv του διαγωνισμού χρησιμοποιήθηκε το Gradient Boosting, καθώς η ακρίβεια των προβλέψεων είναι το σημαντικότερο στα ζητούμενα. **To Gradient Boosting** παρουσίασε τη χαμηλότερη τιμή MSE και το υψηλότερο R^2 στο validation set. Η ικανότητά του

να μοντελοποιεί μη γραμμικές σχέσεις και αλληλεπιδράσεις μεταξύ των χαρακτηριστικών το καθιστά ιδιαίτερα κατάλληλο για δεδομένα κοινωνικοοικονομικών ερευνών.

Επίσης, για τον υπολογισμό του poverty distribution παίρνονται υπόψη οι καταγραφές στα pct_hh_below_#. Από το # προκύπτουν και τα poverty thresholds.


- **Σε ποιες περιπτώσεις τα μοντέλα σας δουλεύουν/δε δουλεύουν καλά.**

Κατά την εκπαίδευση των μοντέλων για την αξιολόγηση τους χρησιμοποιήθηκε MSE και R2 ώστε να συγκριθεί πόσο αστοχούν οι προβλέψεις από τα πραγματικά δεδομένα και πόσο καλά το μοντέλο αντιστοιχα εξηγεί την συνολική διακύμανση στο train set που χρησιμοποιήθηκε. Από τα αποτελέσματα προκύπτει ο παρακάτω πίνακας

Μοντέλο	MSE	R ²	Συμπέρασμα
Lasso Regression	51.54	0.48	Αδυναμία για μη γραμμικά μοτίβα, αλλά γενικά καλό
SVR	62.96	0.37	Το λιγότερο αποδοτικό για complex households
Gradient Boosting	37.39	0.62	Πολύ καλό στα συγκεκριμένα δεδομένα, επείτα απο το fine-tuning που έγινε.
MLP(Deep Learning)	38.85	0.61	Απέδωσε καλά για τα δεδομένα.


- **Σε ποια χαρακτηριστικά δίνουν μεγαλύτερη έμφαση τα μοντέλα σας και πόσο σημαντικά είναι αυτά για την ποιότητα των προβλέψεων.**

Στο Lasso Regression βρέθηκαν τα χαρακτηριστικά που είχαν την μεγαλύτερη επίδραση στις προβλέψεις για περισσότερη κατανάλωση (coefficiency).




Lasso Regression

Στο Gradient Boosting τα σημαντικότερα σχετίζονται με τον αριθμό των μελών , την μόρφωση , την περιοχή και τις παροχές.Αυτά είναι που επηρεάζουν την ακρίβεια των προβλέψεων στο μεγαλύτερο βαθμό.



Gradient Boosting

Στο SVR και MLP τα σημαντικότερα χαρακτηριστικά σχετίζονται το κατά πόσο θα πέσει η απόδοση των προβλέψεων εάν ένα χαρακτηριστικό δεν σχετίζεται πλέον (permutation).
Για MLP,



- **Αποδεικτικό υποβολής / θέσης στο Leaderboard**

New submission

Woohoo, your submission was successful! Your submission score is 83.1730

X Post Done

Best score: None

Current rank: None

Submissions used: 0 of 3

Make new submission

You have 3 of 3 submissions left per 7 days. Your next submission can be on Jan. 28, 2026 UTC.

Your submissions

Navigation

Home
Problem description
About
Official rules
Leaderboard
Discussion (5)
Data download
Submissions (1)
Share your work
Team

Submissions

- To help you track your progress during the competition, each submission is scored against publicly available test data to give a "public score".
- You should select up to 1 submission** to be considered in the final scoring from the table of your submissions that will appear below.
- The primary evaluation metric is a weighted sum of weighted mean absolute percentage error. [Show more.](#)

Best score
83.173

Current rank
#366

Submissions used
1 of 3

Make new submission

You have **2 of 3** submissions left per 7 days. Your next submission can be on Jan. 28, 2026 UTC.

Your submissions

 New submissions won't be autoselected while you're at max selected

Public score	Who	Details	1 of 1 selected
Error	 _lne	id-301071 · 17min ago · 28/01	-

Τρόποι βελτίωσης των δεδομένων

Η ακρίβεια των προβλέψεων θα μπορούσε να βελτιωθεί με μείωση των missing values. Όπως επίσης ίσως θα μπορούσε να προστεθεί και επιπλέον πληροφορία για γεωγραφικές περιοχές όπου παρατηρείται μεγαλύτερη κατανάλωση και poverty distribution ώστε να γίνει πιο εύκολα ομαδοποίηση των περιοχών με πχ παροχές νερού στα καταλύματα. Ή ακόμη και χρονολογικά δεδομένα για το κάθε πότε παρατηρείται μεταβολή στη κατανάλωση και μη.